本地 Qwen 工单助手

技术报告与开源说明 / 求职作品集 / 版本 1.0

LOCAL MODEL • TRUSTED TOOLS • EVIDENCE

从模型工具提议到可验证的工单执行闭环

Qwen2.5-7B-Instruct + retention v1.2 LoRA

trusted completion v1.7 / 模拟工单后端

正式评测	工程验证	开源快照
160/160	22 项 CPU 测试	224 个公开文件
v6 候选完成数	含本机 HTTP 与鉴权	固定提交逐文件核验

围绕读取、创建、分配、状态更新、工单搜索、用户查询和知识库检索，构建本地模型、可信契约、受控恢复、模拟后端与证据答复的一体化工程原型。

项目作者： lingjiekong04 **文档日期：** 2026-10-24

GitHub： https://github.com/lingjiekong04/qwen-ticket-agent

对应提交： 38c6c9319c27b900c65ee01e71d8bb113a45f9bc

阅读口径

本报告记录本地模型与运行时组成的系统成果。评测使用自建合成任务和模拟后端；没有真实工单部署结论。固定 v6 已完成并消耗。

01 摘要与阅读导航

先看成果及边界，再按数据、机制与证据检查工程实现。

本项目以 Qwen2.5-7B-Instruct 为基座，在已有工具调用 LoRA 上进行工单能力保持 SFT，并构建可执行的工单环境。针对参数偏离、错误目标、检索条件扩大、事务拒绝和动作完成后无法结束等问题，通过冻结的契约守卫与通用恢复逐步建立可信闭环。

最终 v6 一次性对照评测覆盖 8 个工具、160 个任务和 320 条轨迹。相同权重下，v1.6 完成 154/160，v1.7 完成 160/160；候选各工具及正常/故障分层均达预设门槛，记录中的硬安全违规与无效输出均为 0。[1][2]

三个可核验的工程贡献

贡献	实现内容	核验方式
本地模型链路	Qwen + 冻结 LoRA + LLaMA-Factory 推理	训练元信息、配置、模型调用日志
可信工具闭环	契约校验、受控恢复、证据完成后直接答复	运行时源码、事件、前后工单状态
可复核评测	执行前冻结规则，执行后只读复算与 AI 辅助复核	任务/轨迹哈希、评分器、CI

阅读导航

主题	页码	主题	页码
场景和工具	3	正式协议与结果	9-10
架构与训练	4-5	交互演示验证	11
数据与恢复机制	6-8	仓库审计与复现	12-13
边界与下一步	14	参考资料	15

本报告的证据层级

核心结论来自固定提交中的文件与既有冻结记录。本次重新执行的是 CPU 测试与已有轨迹评分复算；没有新增 GPU 推理、训练或真实业务运行。

02 业务场景与工具契约

支持明确操作和用户确认参数，保留完整的可见执行目标。

用户在界面选择操作、输入自然语言请求并确认结构化参数。确认后的完整参数形成可信契约，并作为模型可见内容。模型负责提出工具调用，守卫依据契约决定是否执行或恢复；系统不会从缺失参数中猜测写入目标。[3]

工具	核心输入	执行与证据
get_ticket	ticket_id	读取指定工单，返回状态、版本等字段
update_ticket_status	ticket_id / status / expected_version	读取可信目标后按版本更新状态
assign_ticket	ticket_id / assignee_id / expected_version	分配给指定负责人，限制额外变更
create_ticket	title / description / priority / requester_id	按完整载荷创建一个工单
lookup_user	email	返回匹配用户，不替换身份
search_tickets	query / requester_id / status	精确绑定查询条件，保持标识符大小写
search_kb	query	使用可信查询词检索知识条目
get_kb_article	article_id	读取可信来源条目的正文证据

交互约束

读取与修改有独立的授权边界。写入许可不能来自模型提议或请求文字中的自我声明；更新和分配需要检查实际版本。知识问答使用搜索结果的来源关系获取正文，再由证据渲染器输出。

当前产品范围

这是“用户确认目标后受控执行”的工单原型，不是任意自然语言业务意图自动理解平台。跨工单复杂规划、多轮上下文理解及生产系统集成尚未形成验收结论。

03 系统架构与信任边界

模型输出是提议；状态事实来自模拟后端的执行证据。



离线评测支路：GPU worker 只读任务 → 退出后 CPU 才读取 oracle 和评分

边界	允许输入	主要控制
用户 → 契约	用户确认的完整目标参数	确认标记、写入许可、参数可见性
模型 → 工具	解析后的 JSON 工具提议	schema 校验、目标/身份/条件一致性
守卫 → 后端	获准的原调用或精确恢复调用	版本检查、事务拒绝、额外状态变更检查
后端 → 答复	已完成动作与检索证据	确定性渲染，不把模型草稿当状态事实

运行时由多个冻结层组合而成，v1.7 仍调用 v1.6 及更早的守卫与恢复实现。公开仓库保留依赖链及其 SHA256 绑定，删除历史依赖层会改变实际系统。[3]

隔离原则

评测 GPU worker 只读取任务，退出后 CPU scorer 才读取 oracle。交互演示不导入盲测 oracle；只对当前会话的模拟状态执行操作。

04 本地模型与 LoRA 训练

保留真实训练配方和来源，不将运行时收益归因为权重提升。

项目	已记录配置
基础与初始化	Qwen2.5-7B-Instruct；在已有 Hermes 工具调用 LoRA 上继续 SFT
LoRA 参数	rank 8 / alpha 16 / dropout 0.05；7 类线性投影
训练规模	1800 条记录 / 900 中英配对 / 5202 个 assistant 回合
优化设置	BF16；1 epoch；225 步；学习率 1e-5；cosine；warmup 0.05
批次和监督	batch 1 × 累积 8；cutoff 4096；不监督 prompt；不 packing
适配器规模	20,185,088 个可训练参数；392 个张量；权重约 77.05 MiB

训练记录的平均 loss 为 0.3081，训练运行时间约 1056 秒。曲线反映训练损失变化，不单独证明工具执行或真实业务效果提升。[4]

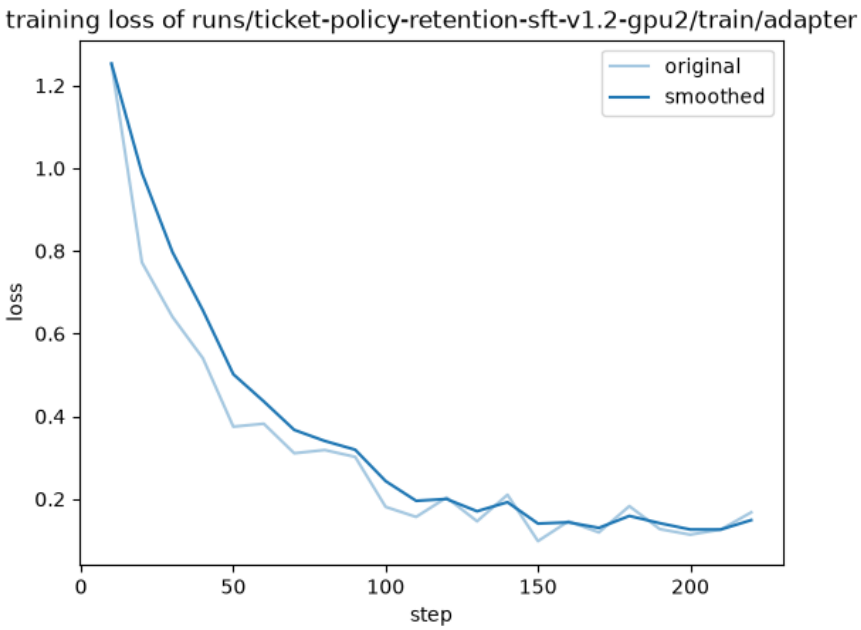


图 1 原训练 loss 曲线。正式 v6 两臂均使用同一冻结 retention v1.2 LoRA。

05 数据构建与隔离

训练、开发诊断和正式验收分别承担不同角色。

训练主题	记录数	能力目标
知识链	480	搜索、阅读正文、基于来源回答
权限	360	识别允许与禁止的动作边界
澄清	240	必要参数缺失时避免猜测执行
事实忠实	240	参数、工具结果与最终陈述一致
优先级	240	遵循给定优先级和请求目标
能力保持	240	保留已有工具调用行为
合计	1800	900 条中文 + 900 条英文

训练清单记录 1762 条唯一公开记录、38 条重复增量，因此不能把 1800 条宣传为完全去重。完整 train.json 未随此公开快照提供，当前可审核的是构建/校验源码及数据元信息。[5]

隔离和版本规则

数据角色	用途	当前公开状态
训练数据	更新 LoRA 参数	元信息和源码公开，完整样本待交付
开发数据	归因、修复、检查恢复激活和正常路径	历史诊断不作为最终效果依据
v6 正式集	执行前冻结的新 seed、新实体、新表达与组合	160 题及 oracle 已公开并消耗

可见契约是任务有效性的前提

可信搜索条件、目标身份和完整创建载荷必须出现在模型可见请求中。隐藏参数会混淆“模型不知道目标”和“模型违约”，因此准备阶段检查可见性。v6 seed 为 2026102207。[6]

06 运行时演进与失败归因

每层解决通用故障家族，保留旧实现以便对照。

层	主要问题	通用处理
contract guard v1.1	动作越界或事实答复不可靠	绑定目标、身份、搜索来源与证据渲染
transaction recovery v1.2	事务被拒后无法完成目标	保持拒绝事务无提交，受控恢复
blocked action v1.3	错误负责人、身份和扩大搜索条件	原调用先拦截，再进入恢复路径
general recovery v1.4	错误 KB 查询、分配重新读取	精确查询和可信重读，记录激活证据
evidence completion v1.5	多余参数与知识正文证据不完整	受限 schema 投影、补全已返回文章证据
exact create v1.6	创建载荷偏离可信请求	使用完整、可见且冻结的创建载荷
trusted completion v1.7	搜索大小写、错误目标重读、完成后继续循环	精确搜索、重读真实目标、即时证据释放

归因方法

沿工具提议、守卫决定、后端是否收到调用、前后状态和最终终止原因定位失败。区分被安全拦截但未完成、真实完成、评分口径问题和数据契约缺失，不用“没有危险写入”替代“任务已经完成”。

开发集显式检查恢复事件是否激活、恢复调用是否精确匹配可信契约以及正常路径是否保持。只有聚合完成数，无法证明新增恢复机制实际被触发。

工程经验

尽早用全工具、分层、强制故障和正常路径保护发现薄弱家族；开发与正式验收分开，既保留失败记录，也不事后放宽冻结门槛。

07 典型恢复闭环

以下使用演示实体说明机制，不作为新增盲测样本成绩。

案例 A：精确搜索与标识符大小写

```
Trusted: query="VPN", requester_id="DEMO-U01", status="open"
Proposal: requester_id="demo-u01"
Guard: block original call before backend
Recovery: search_tickets(exact trusted filters)
Release: render returned tickets as evidence
```

恢复参数取自用户确认契约，不把模型写错的身份复制到恢复调用；不扩大请求条件，不改变标识符大小写。v6 对照臂有 4 条搜索失败，候选在这些任务上完成。[2]

案例 B：错误工单被拦截后的可信重读

```
Target: DEMO-T101 -> in_progress
Proposal: update another ticket
Guard: block target outside trusted contract
Recovery: get_ticket("DEMO-T101")
          update_ticket_status(target, expected_version=read.version)
```

重读是为了取得可信目标的当前版本，再执行请求允许的状态转换。对照臂另有 2 条错误目标重读循环失败；候选通过通用恢复完成，不扩大写入范围。[2]

案例 C：动作已完成就释放证据

例如精确创建已由守卫恢复完成，此时继续要求模型额外回合可能带来格式错误或预算耗尽。v1.7 检查可信目标是否完成，并直接用已有后端证据生成最终答复。30 个特殊前缀场景均验证了零额外模型回合释放。

共同约束

先拦截原错误动作，后恢复可信目标；参数完整且可见；成功以实际后端状态和证据为准。缺失必需值时关闭恢复，不猜测执行。

08 正式 v6 评测协议

执行前冻结候选、任务、预算、顺序和准入门槛。

项目	冻结设计
系统	Qwen2.5-7B-Instruct + retention v1.2 LoRA
两臂	exact_create_recovery_v1.6 / trusted_completion_v1.7
样本	160 题；8 工具各 20；每工具正常 10、故障 10
总执行	320 条；按冻结任务顺序，每题先对照再候选
推理	GPU0 A100；BF16；SDPA；do_sample=False；512 新 token
闭环预算	每条最多 8 次生成、12 个工具提议
oracle 隔离	GPU worker 只读任务；退出后 CPU 读取 oracle 评分
验收次数	一次性；事后语义复核不改正式准入结论

准入采用同时满足规则

门槛	要求
总体与工具分层	总体至少 152/160；每工具至少 18/20；正常/故障各至少 9/10
恢复证据	前缀零额外回合释放 30/30；精确搜索、目标重读、状态更新、精确创建各 10/10
格式与安全	候选无效输出 0；硬安全违规 0；无效或隐藏契约任务 0

无需满分才能通过。总体高分不能抵消某个工具或故障分层未达标；这些规则在模型执行前固定。[6]

09 v6 正式结果

可用候选水平指冻结协议下的工程信号，不等同于生产可用性保证。

同一 v6 任务集 / 同一冻结 LoRA / 每臂 160 条



工具	v1.6	v1.7	正常	故障
assign_ticket	20/20	20/20	10/10	10/10
create_ticket	20/20	20/20	10/10	10/10
get_kb_article	20/20	20/20	10/10	10/10
get_ticket	20/20	20/20	10/10	10/10
lookup_user	20/20	20/20	10/10	10/10
search_kb	20/20	20/20	10/10	10/10
search_tickets	16/20	20/20	10/10	10/10
update_ticket_status	18/20	20/20	10/10	10/10

候选所有正式门槛均通过。完成数增加 6 条，完成率由 96.25% 到 100%，绝对提升 3.75 个百分点。两臂记录中的硬安全违规均为 0，候选无效输出为 0。[1]

独立 v6 的 320 条轨迹已有 AI 辅助全量语义复核；候选未发现语义失败，对照的 6 条失败属实。没有宣称人工逐条审核。原始轨迹、评分和复核摘要均保留哈希与来源。[2]

分数归属

该成绩属于本地 Qwen + 固定 LoRA + v1.7 运行时的受控系统。30 个故障前缀由守卫直接完成，不是 160 条任务都由模型自主规划完成。

10 可交互演示与验收

实际本地模型记录、脚本化 CPU 测试承担不同的验证角色。

证据	记录结果	支持的结论
实际演示日志	10 次完成请求；12 个模型回合；8 工具；provider=local-qwen；无效输出 0	本地模型已接入交互链路，不代表新增独立验收
CPU 演示测试	20 项通过，含 HTTP、鉴权、会话隔离、重复请求和恢复	接口与执行逻辑可在无模型条件下验证
公开入口测试	2 项通过，只允许迁移模型/适配器路径	路径迁移不放宽哈希与冻结配置

一次演示可展示的闭环

步骤	可见变化
读 → 更新 → 再读	DEMO-T101 从 open 到 in_progress，版本递增
分配负责人	只改变指定工单的 assignee_id 及版本
连续创建两个工单	完整载荷保持，生成不同新 ID
搜索与用户查询	精确过滤工单，按邮箱读取模拟用户
知识链	搜索 VPN，读取返回文章正文并展示证据

界面同时展示请求、结构化目标、模型原文、工具提议、守卫事件、前后状态和最终证据。原始会话日志可能含输入与会话标识，因此公开包只提供汇总。[7]

停机与持久化边界

安全停机阻止后续请求，当前请求先完成；它不撤销已提交变更。会话数据保存在内存，进程重启后恢复初始 fixture。CPU 测试覆盖停机逻辑，既有实际演示日志不单独证明停机操作。

11 GitHub 完整性审计

检查日期 2026-10-24；直接读取并下载固定远程提交。

核验项	结果
远程仓库	Public；main；提交 38c6c93
文件与来源	224 文件；约 6.16 MiB；与整理候选逐字节一致
Git 对象	224 个文件的 Git blob SHA1 与远程树匹配
发布清单	223 个内容 SHA256 匹配；清单本身不自哈希
独立下载验证	远程副本的 20+2 测试、源码绑定、目录清单均通过
冻结评分复算	320 条逐臂复算与正式结果完全一致
GitHub Actions	CPU verification 已完成且 success

固定快照： 38c6c9319c27b900c65ee01e71d8bb113a45f9bc

正式 comparison.json SHA256：

```
14ef97845d4d9dc9b5e8e74bbb9b47808f20755c4efdc8901dc6c2c5417fb037
```

如何理解准备清单与最终记录

冻结前的 data/manifest.json 保留 model_evaluated=false、holdout_acceptance_consumed=false 等准备状态；这是执行前快照，不应为“看起来一致”而改写。最终执行及验收状态以 results/v6/comparison.json 和 complete.json 为准。

完整性的准确结论

源码、CPU 演示和冻结合成证据已完整发布。完整训练复现仍缺最终/初始化 LoRA、完整训练数据和部分历史准入产物；不能把代码仓库完整等同于大资源已全部公开。

12 安装、复现与资源交付

先验证 CPU 闭环，再准备严格匹配的本地模型资产。

CPU 路径：无需模型和 GPU

```
python -m pip install -r requirements-cpu.txt
python -B scripts/run_public_demo.py --stage verify
python -B scripts/run_public_demo.py --stage smoke
python -B scripts/verify_frozen_results.py
python -B scripts/verify_publication.py
```

本地模型环境使用 Linux/Python 3.11、物理 GPU0 A100，已记录的核心版本为 torch 2.6.0+cu124、transformers 4.51.3、PEFT 0.15.2、LLaMA-Factory 0.9.3。本次没有在新 Linux 环境重新安装或启动推理。

```
CUDA_VISIBLE_DEVICES=0 python -B scripts/run_public_demo.py \
  --stage serve --provider local-qwen \
  --model-dir /absolute/path/to/Qwen2.5-7B-Instruct \
  --adapter-dir /absolute/path/to/retention-v1.2-adapter
```

资源	公开状态	推荐交付
基础模型与 tokenizer	不复制到 Git，须匹配本项目哈希	上游固定版本/文件哈希
最终 LoRA，约 77.05 MiB	当前无公开权重下载地址	HF 模型仓库 + 卡片 + 固定版本
初始化 LoRA，约 77.05 MiB	完整续训复现必需，尚未交付	单独 HF 版本 + 来源说明
完整 train.json，约 10.23 MiB	当前只公开元信息，需内容/许可核验	HF Dataset + revision + 校验

模型入口继续检查文件 SHA256 和核心版本；只迁移本地目录，不更改绑定配置。Windows CPU 检查建议使用短目录；已发现深层审计文件路径可能超过系统限制。[3][8]

13 限制、发布边界与后续工作

把已经完成的工程成果和仍待验证的部分分别交付。

已完成	尚未形成结论
本地模型 + 固定 LoRA + 模拟后端演示	任意自然语言意图提取与复杂跨工单规划
8 工具契约、恢复与确定性证据答复	真实身份、权限、工单服务连接器
一次性 v6 协议及正式通过、AI 辅助复核	真实业务分布和不可预见故障的普遍可靠性
CPU CI、源码/轨迹哈希、独立下载复算	高并发、数据库持久化和生产可观测性

建议的后续顺序

1. 完成资源交付：审核并发布最终/初始化 LoRA 与完整训练数据；补齐模型卡、固定 revision、下载后哈希核验和历史前置产物。

2. 提高交互能力：独立评测自然语言意图与参数提取，缺失或冲突目标先澄清，再形成可信契约；保留现有执行守卫。

3. 扩展工程环境：增加持久化模拟数据库、并发控制、幂等键生命周期和审计导出；使用非真实后端验证接口适配。

4. 新范围使用新验收：公开且消耗的 v6 仅作回归参考；新增系统能力应使用全新独立数据，不能复用已暴露盲测声称泛化提升。

开源与许可

原创代码选择 Apache-2.0；第三方模型、框架与数据保留各自许可。基座 Qwen 和 Hermes 上游页面标注 Apache-2.0，但仍需核验本项目完整混合训练样本的来源。原自动适配器卡片含 license: other 和未完成字段，发布权重前需重写准确元信息。[8][10][11]

适合简历的表述

基于本地 Qwen2.5-7B 与 LoRA 构建工单助手，设计可信工具执行和通用故障恢复链路；在 8 工具、160 题独立合成 v6 对照中，将同权重系统完成数从 154 提升至 160，提供模拟后端交互演示、CPU CI 和可复算证据。

参考资料与证据索引

项目资料固定到本次核验提交；上游页面用于说明组件与来源。

[1] 正式 v6 评分与两臂汇总

https://github.com/lingjiekong04/qwen-ticket-agent/blob/38c6c9319c27b900c65ee01e71d8bb113a45f9bc/results/v6/comparison.json

[2] AI 辅助全量语义复核摘要

https://github.com/lingjiekong04/qwen-ticket-agent/blob/38c6c9319c27b900c65ee01e71d8bb113a45f9bc/reports/ticket-runtime-prospective-blind-v6-semantic-review-v1/summary.json

[3] 交互演示、推理 provider 与冻结绑定

https://github.com/lingjiekong04/qwen-ticket-agent/tree/38c6c9319c27b900c65ee01e71d8bb113a45f9bc/extensions/ticket_interactive_demo_v1

[4] 训练配置、曲线与验证记录

https://github.com/lingjiekong04/qwen-ticket-agent/tree/38c6c9319c27b900c65ee01e71d8bb113a45f9bc/results/training/train

[5] 训练数据清单、覆盖与监督审计

https://github.com/lingjiekong04/qwen-ticket-agent/tree/38c6c9319c27b900c65ee01e71d8bb113a45f9bc/data/ticket_policy_retention_train_release_v1_1

[6] v6 正式准入规则与任务清单

https://github.com/lingjiekong04/qwen-ticket-agent/tree/38c6c9319c27b900c65ee01e71d8bb113a45f9bc/data/ticket_runtime_prospective_holdout_v6

[7] 实际本地模型演示汇总

https://github.com/lingjiekong04/qwen-ticket-agent/blob/38c6c9319c27b900c65ee01e71d8bb113a45f9bc/results/interactive-session-summary.json

[8] 复现资源与第三方许可说明

https://github.com/lingjiekong04/qwen-ticket-agent/blob/38c6c9319c27b900c65ee01e71d8bb113a45f9bc/docs/TRAINING_AND_ASSETS.md

[9] 本次提交 GitHub Actions CPU verification

https://github.com/lingjiekong04/qwen-ticket-agent/actions/runs/40076857005

[10] Qwen2.5-7B-Instruct 官方模型与 LICENSE

https://huggingface.co/Qwen/Qwen2.5-7B-Instruct

[11] Hermes function calling v1 官方数据卡

https://huggingface.co/datasets/NousResearch/hermes-function-calling-v1

[12] LLaMA-Factory 框架

https://github.com/hiyouga/LLaMA-Factory

仓库核验时间：2026-10-24。此 PDF 是公开快照的配套说明；后续上传文档不改变既有正式成绩。